

이미지 분류 모델의 잠재공간에서 데이터 분포에 따른 노이즈 강건성의 기하학적 분석

이은성¹ · 박현철^{1,*}

¹국립한국교통대학교

Geometric Analysis of Noise Robustness According to Data Distribution in the Latent Space of Image Classification Models

Eun-Sung Lee¹ · Hyun-Cheol Park^{1,*}

¹Korea National University of Transportation

E-mail : xkfkxbffk12@u.ac.kr / hc.park@ut.ac.kr

요 약

본 연구에서는 다양한 이미지 분류 모델의 2D 임베딩 공간을 분석하여, 원점으로부터의 거리와 노이즈 강건성 사이의 관계를 규명하고자 한다. 특히 학습 초기 단계에서 높은 예측 확신도로 정분류되는 일부 샘플이 2D 임베딩 공간에서 원점 부근에 분포하는 경향이 있으며, 이러한 관점에서 원점에 가까이 분포하는 데이터들이 원점에서 멀리 분포하는 데이터들에 비해 노이즈가 추가되었을 때 더 높은 오분류율을 보일 수 있다는 가설을 정량적으로 검증한다. 본 실험에서는 대표적인 분류 모델들인 VGG16, ResNet50, ViT-B 등을 이용하여 2D 임베딩 공간을 구성하고, 다양한 입력 노이즈가 부가된 환경에서 원점으로부터의 거리 구간별 강건성 평가를 수행하였다. 이때 입력 노이즈는 Gaussian noise, Salt-and-pepper noise, Speckle noise, Gabor noise, Perlin noise, Adversarial noise의 6종으로 구성하였고, Cosine Similarity를 통하여 평가하였다. 실험 결과, 원점 부근의 벡터가 외곽 벡터보다 노이즈에 더 취약한 경향을 보였으며, 이는 2D 임베딩 공간에서의 기하학적 위치가 분류 모델의 강건성을 해석하는 중요한 단서가 될 수 있음을 시사한다.

ABSTRACT

In this study, we analyze the 2D embedding spaces of various image classification models to investigate the relationship between the distance from the origin and robustness to noise. In particular, we observe that some samples that are correctly classified with high confidence at an early stage of training tend to be distributed near the origin in the 2D embedding space. From this perspective, we quantitatively examine the hypothesis that data located closer to the origin may exhibit higher misclassification rates under added noise than data located farther from the origin. In the experiments, we constructed 2D embedding spaces using representative classification models such as VGG16, ResNet50, and ViT-B, and performed robustness evaluations across distance intervals from the origin under various input noise conditions. The input perturbations consisted of six types: Gaussian noise, salt-and-pepper noise, speckle noise, Gabor noise, Perlin noise, and adversarial noise, and the similarity of each vector was evaluated using cosine similarity. The experimental results show that vectors located near the origin tend to be more vulnerable to noise than those located farther away, suggesting that the geometric position in the 2D embedding space can serve as an important clue for interpreting the robustness of classification models.

키워드

Image Classification, Geometric Analysis, Noise Robustness, Feature Representation

* 교신저자

I. 서 론

최근 딥러닝 기반 이미지 분류 모델은 다양한 데이터셋에서 높은 정확도를 달성하며 컴퓨터 비전 분야의 핵심 기술로 자리 잡았다. VGG[1], ResNet[2], ViT[4]와 같은 대표적인 모델들은 복잡한 시각적 특징을 효과적으로 추출하지만, 입력 영상에 미세한 노이즈나 다양한 형태의 노이즈가 추가될 경우 그 성능이 급격히 저하되는 취약점을 안고 있다.[7]-[8], 따라서 단순히 모델의 최종 예측 결과를 확인하는 것을 넘어, 입력 데이터가 모델 내부의 잠재 공간에서 어떠한 구조로 분포하는지 파악하는 것은 모델의 안정성과 해석 가능성을 이해하는 데 필수적이다. 이는 동일한 분류 결과를 보이는 샘플이라 하더라도 내부 표현의 위치에 따라 노이즈 민감성이 달라질 수 있음을 시사한다.

기존의 강건성 연구는 주로 입력 노이즈나 적대적 공격에 따른 정확도 하락, 혹은 특정 방어 기법의 성능 검증에 집중되어 왔다. 이러한 거시적 접근은 모델의 외형적 성능 변화를 정량화하는 데는 유용하지만, 잠재 공간 내에서 데이터의 기하학적 위치가 노이즈 취약성과 어떠한 상관관계를 갖는지에 대한 근본적인 설명은 제공하지 못한다. 이에 따라 본 연구는 고차원 특징을 2차원(2D) 임베딩 공간으로 투영하여 데이터의 상대적 위치와 분포 구조를 시각적으로 분석하고, 위치적 특성과 강건성 간의 연관성을 해석하고자 한다.

특히, 선행 연구[9]-[10]에서 보고된 바와 같이 학습 초기 단계에서 높은 예측 확신도로 정분류되는 일부 샘플들이 2D 임베딩 공간 상의 원점 부근에 집중적으로 분포하는 경향에 주목하였다. 이를 바탕으로, 원점에 가까이 분포하는 데이터가 외곽에 위치한 데이터에 비해 노이즈 인가 시 더 큰 표현 왜곡과 높은 오분류 가능성을 보일 수 있다는 기존 해석을 다양한 모델과 이질적인 노이즈 조건에서 재검토함으로써, 해당 가설의 정량적 타당성과 일반성을 강화하고자 하였다.

이를 위해 본 연구에서는 6종의 이미지 분류 모델의 최종 특징표현을 기반으로 2D 임베딩 공간을 구성하고, 각 데이터 벡터를 원점 기준 거리 구간으로 나누어 6종의 서로 다른 특성을 지닌 노이즈를 입력 영상에 적용하여 노이즈 인가 전후의 분류 성능과 임베딩 분포 변화를 비교한다. 나아가 원본 벡터와 노이즈 벡터 간의 코사인 유사도를 측정함으로써 잠재표현 변화의 정도를 정량적으로 평가하고, 잠재 공간 내 위치적 특성과 노이즈 강건성의 관계를 검증하고자 한다.

II. 제안 방법

2.1 2D 임베딩 공간 정의

이미지 분류 모델의 잠재 표현이 노이즈에 대해 보이는 구조적 특성을 분석하기 위해, 각 입력 샘

플의 최종 출력층 직전 마지막 은닉층에서 추출된 특징 벡터를 2D 임베딩 공간으로 사상한다. 일반적으로 고차원 특징 공간은 직접적인 시각화와 해석이 어려우므로, 분류 직전 단계의 잠재 표현을 2차원 좌표 (l_1, l_2) 로 변환하여 상대적 위치와 분포 양상을 분석한다. 이에 따라 각 샘플 i 의 2D 임베딩 벡터는 다음과 같이 정의된다.

$$z_i = (l_{1,i}, l_{2,i}) \quad (1)$$

또한 각 벡터가 원점으로부터 얼마나 떨어져 있는지를 나타내기 위한 원점 기준 거리 r_i 를 유클리디안 거리로 정의한다.

$$r_i = \sqrt{l_{1,i}^2 + l_{2,i}^2} \quad (2)$$

거리 r_i 를 바탕으로 원점에서부터 최대 반지름까지의 범위를 20개의 균등한 구간으로 분할한다.




그림 1. 2D 임베딩 공간 내 원점 기준 거리(r_i) 기반 20분할 구간 모식도

2.2 코사인 유사도

원점 기준 위치에 따른 노이즈 민감도를 평가하기 위해, 원본 입력과 노이즈가 추가된 입력의 2D 임베딩 벡터를 비교 분석한다. 입력 샘플에 노이즈가 인가되면 해당 샘플의 잠재 표현은 기존 좌표에서 새로운 좌표로 이동하게 되며, 이 변위 정도는 노이즈에 대한 표현 안정성을 대변하는 직접적인 척도가 된다. 원본 입력의 벡터를 z_i , 노이즈가 추가된 입력의 벡터를 z'_i 라고 할 때, 두 벡터 간의 유사성은 다음과 같이 코사인 유사도로 측정한다.

$$\text{Cosine Similarity}(z_i, z'_i) = \frac{z_i \cdot z'_i}{\|z_i\| \|z'_i\|} \quad (3)$$

코사인 유사도는 두 벡터의 방향 보존 정도를 나타내며, 값이 1에 가까울수록 노이즈 인가 전후의 표현이 온전히 유지되었음을 의미한다. 이를 검증하고자 노이즈를 적용하고, 각 거리 구간별로 코사인 유사도 변화 양상을 비교하여 원점 부근 샘플의 표현 왜곡 정도를 정량화한다.

2.3 노이즈에 의한 벡터 이동과 기하학적 해석

본 연구에서는 외부 노이즈가 잠재 표현에 미치는 영향을 단순한 수치적 성능 저하가 아니라, 2D 임베딩 공간 내에서의 벡터 방향 변화로 해석한다. 이를 위해 샘플 i 의 노이즈 전가 이후의 이동거리 d_i 를 다음과 같이 정의한다.

$$d_i = \|z_i - z'_i\|_2 \quad (4)$$

d_i 는 동일 샘플의 잠재 표현이 노이즈에 의한 이동한 정도를 나타내는 스칼라 거리값이다.




그림 2. 원점 거리에 따른 각도 변위 비교

그림 2는 동일한 이동 거리 d_i 에 대해 원점 거리 r_i 가 작은 벡터에서 각도 변화 $\Delta\theta_{close}$ 가 크게 나타나고, 원점 거리 r_i 가 큰 벡터에서는 각도 변화 $\Delta\theta_{far}$ 가 상대적으로 작게 나타남을 보여준다.

이러한 차이는 벡터의 크기, 즉 원점으로부터의 거리 r_i 에 의해 결정된다. 동일한 크기의 노이즈가 주어지더라도 r_i 가 작은 벡터는 방향이 크게 흔들리는 반면, r_i 가 큰 벡터는 방향 변화가 상대적으로 제한된다. 이러한 기하학적 차이는 코사인 유사도가 더 큰 쪽으로 감소하는 현상으로 직접 연결되며, 결과적으로 원점 인접 샘플이 외곽 샘플보다 노이즈에 대해 민감하다는 사실을 증명한다.

나아가 이러한 벡터 이동의 차이는 모델이 형성한 결정 경계를 이탈할 확률이 높아지며, 이는 곧 오분류율의 증가로 이어진다.

III. 실험

3.1 실험 설정

실험에는 ImageNet 데이터셋 중 10개 클래스를 선택하여 사용한다. 모든 입력 이미지는 256 해상도로 resize한 뒤 224×224 크기로 crop하여 모델에 입력하며, 총 6종의 이미지 분류 모델 (VGG16[1], ResNet50[2], EfficientNetB0[3], ViT-B[4], Swin-T[5], ConvNeXt-T[6])은 모두 사전 학습된 가중치를 기반으로 사용한다. 이후 각 모델의 분류 직전 특징 표현이 2차원 임베딩 공간에 투영되도록 마지막

은닉층을 fine-tuning하였으며, 모든 모델에 동일한 전처리, 학습 조건, 평가 절차를 적용한다.

노이즈는 입력 이미지에 직접 추가하는 방식으로 적용하며, Gaussian noise, Salt-and-pepper noise, Speckle noise, Gabor noise, Perlin noise, Adversarial example[11]의 총 6종을 사용한다. 각 노이즈 조건에서 분류 성능 변화와 2차원 임베딩 공간에서의 분포 변화를 비교하고, 원점 거리와 노이즈 민감도 사이의 관계를 분석한다.

학습은 총 100 epoch 동안 수행하고, batch size는 64로 설정한다. 최적화 알고리즘은 AdamW를 사용하며, 학습률과 가중치 감쇠는 10e-4로 설정한다. 스케줄러는 Cosine Annealing을 적용하여 전체 학습 과정에서 점진적으로 감소하도록 한다.

3.2 노이즈 적용 전후 조건에서의 2D 임베딩 분포 및 분류 성능

본 절에서는 노이즈 미적용 및 적용 조건에서 각 모델의 2D 임베딩 공간($(l_{1,i}, l_{2,i})$)에서의 분포 변화를 비교한다.




그림 3. 노이즈 미적용 조건에서의 분포




그림 4. Perlin 노이즈 적용 조건에서의 분포

그림 3은 각 모델의 분류 직전 특징 벡터를 2D 임베딩 공간에 사상한 결과로, 클래스별 군집 구조가 형성됨을 보여준다. 다만 군집 간 분리 정도와 원점 주변의 밀집 양상은 모델마다 차이를 보인다.

그림 4는 6종의 노이즈 중 Perlin 노이즈 적용 시 각 모델의 2D 임베딩 분포 변화를 나타낸다. 노이즈가 인가되면 clean 조건에서 형성되던 군집 구조가 부분적으로 붕괴되거나 클래스 간 경계가 흐려지는 경향이 나타난다. 이는 입력 교란이 분류 직전 잠재 표현의 기하학적 구조를 변화시킬 수 있음을 보여준다.

3.4 원점 거리 구간별 노이즈 강건성 분석

본 절에서는 각 모델의 원점 거리 구간별 분류 정확도와 코사인 유사도 변화를 각 노이즈 별로 비교하여, 잠재 공간 내 위치와 노이즈 강건성의 관계를 분석한다.

그림 5~8은 각각 VGG16[1], ResNet50[2], ViT-B[4], ConvNeXt-T[6] 모델의 분석 결과를 보여 준다. 전체 실험은 6개 모델을 대상으로 수행하였으나, 본문에 포함되지 않은 두 모델 역시 전반적으로 유사한 경향을 보여 생략하였다.

각 그림의 상단 그래프에서 x축은 원점 거리를 의미하며, 왼쪽 y축은 clean 및 각 노이즈 조건에서의 구간별 분류 정확도를 직선 그래프로 나타낸다. 오른쪽 y축은 각 구간에 포함된 벡터 수를 막대그래프로 나타낸다. 하단의 6개 그림은 좌상단부터 순서대로 Gaussian, Salt-and-pepper, Speckle, Gabor, Perlin, Adversarial example[11] 조건에서의 코사인 유사도를 2D 임베딩 공간 위에 클래스별로 시각화한 것이다. 색이 진할수록 코사인 유사도가 높고, 클래스별 구간 내 벡터 수가 5개 이하인 경우, 신뢰도를 고려하여 흰색으로 표시한다.

전반적으로 원점에 가까운 구간에서 노이즈 인가 후 분류 정확도와 코사인 유사도가 더 크게 감소하는 경향이 관찰된다.




그림 5. VGG16




그림 6. ResNet50




그림 7. ViT-B




그림 8. ConvNext-T

IV. 고 찰

본 연구에서는 다양한 이미지 분류 모델의 2D 임베딩 공간 내 데이터의 기하학적 위치와 노이즈 강건성 사이의 관계를 원점 거리 구간에 따라 데이터를 분할한 뒤 노이즈 인가 전후의 분류 정확도와 코사인 유사도 변화를 비교하였다.

실험 결과, 노이즈가 적용되면 clean 조건에서 형성되던 군집 구조가 부분적으로 붕괴되거나 클래스 간 경계가 흐려지는 경향이 나타났으며, 이러한 변화는 모델마다 서로 다른 양상으로 관찰되었다. 또한 전반적으로 원점에 가까운 구간의 샘플일수록 노이즈 인가 후 코사인 유사도 감소폭과 분류 성능 저하가 크게 나타나는 경향을 확인하였다. 이는 잠재 공간에서의 위치적 특성이 노이즈 민감성과 관련될 수 있음을 시사한다.

그러나 이러한 경향이 모든 모델과 모든 구간에서 일관되게 나타난 것은 아니다. 특히 Transformer 기반 모델에서는 원점 인접 구간뿐 아니라 중간 구간에서도 변동성이 크게 나타났다. 이는 원점 거리 구간이 노이즈 강건성을 해석하는 유의미한 지표이지만, 모든 모델에 대해 절대적인 기준으로 적용되기에는 한계가 있음을 보여준다.

그럼에도 불구하고 본 연구는 전체 정확도 비교를 넘어, 원점 거리 구간별 정확도와 코사인 유사도를 함께 분석함으로써 잠재 공간의 위치적 특성과 노이즈 강건성의 연관성을 정량적으로 확인하였다는 점에서 의의를 가진다.

향후에는 Transformer 계열에서 나타나는 비단조적 패턴의 원인을 추가적으로 규명할 필요가 있으며, 2차원 임베딩 공간에서 관찰된 경향이 실제 고차원 특징 공간에서도 유지되는지 검증하고, 원점 인접 또는 특정 중간 구간에서의 취약성을 완화할 수 있는 학습 전략으로 확장할 필요가 있다.

Acknowledgement

본 연구는 2025년 국립한국교통대학교 지원을 받아 수행하였음.

References

- [1] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," International Conference on Learning Representations (ICLR), 2015.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.
- [3] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," Proceedings of the 36th International Conference on Machine Learning (ICML), 2019, pp. 6105–6114.
- [4] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," International Conference on Learning Representations (ICLR), 2021.
- [5] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows," Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2021, pp. 10012–10022.
- [6] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022, pp. 11976–11986.
- [7] D. Hendrycks and T. Dietterich, "Benchmarking Neural Network Robustness to Common Corruptions and Perturbations," International Conference on Learning Representations (ICLR), 2019.
- [8] A. Ilyas, S. Santurkar, D. Tsipras, L. Engstrom, B. Tran, and A. Madry, "Adversarial Examples Are Not Bugs, They Are Features," Advances in Neural Information Processing Systems (NeurIPS), 2019.
- [9] L. van der Maaten and G. Hinton, "Visualizing Data using t-SNE," Journal of Machine Learning Research (JMLR), 2008.
- [10] H.-C. Park and S.-W. Lee, "The Role of Feature Vector Scale in the Adversarial Vulnerability of Convolutional Neural Networks," Mathematics, vol. 13, no. 18, p. 3026, 2025.
- [11] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and Harnessing Adversarial Examples," International Conference on Learning Representations (ICLR), 2015.